FIAP

Pós Tech · Tech Challenge · Fase 2

CLASSIFICANDO A QUALIDADE DE VINHOS COM MACHINE LEARNING

Aneli Eiko Abe
Carolina Estevam Rodgerio
João Vitor Morais Santos
Luis Felipe Brum Marinato
Pedro Andrade da Silva

1.018
vinhos analisados

11
medidas físico-químicas

2
modelos comparados:
KNN e SVM

01 · CONTEXTO

O DESAFIO DO ENÓLOGO

Hoje

- A qualidade é julgada por especialistas, pela prova
- Aroma, sabor, acidez e equilíbrio
- Processo subjetivo, demorado e dependente da experiência

Oportunidade

- Medidas químicas já são coletadas durante a produção
- Modelos preditivos podem apoiar a decisão
- Mais padronização e agilidade na avaliação

Pergunta do projeto: a química do vinho indica quais são de alta qualidade (nota 7 ou mais)?

02 · EXPLORAÇÃO DOS DADOS

OS DADOS ANALISADOS

1.143
amostras na base original

0
valores nulos

125
registros duplicados removidos

1.018
vinhos para análise e modelagem

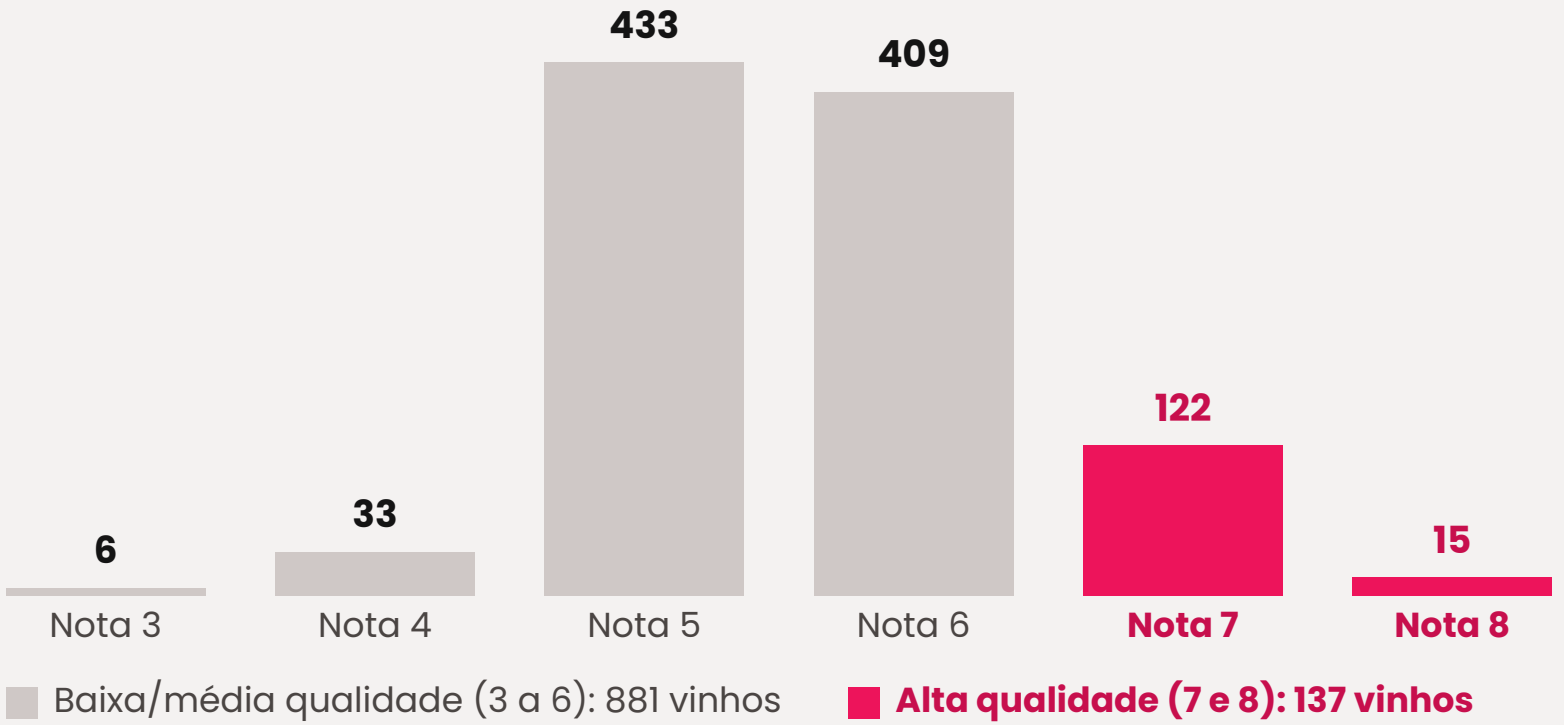
11 medidas físico-químicas por vinho, e a nota de qualidade (3 a 8) dada por especialistas

Acidez fixa · Acidez volátil · Ácido cítrico · Açúcar residual · Cloretos · Enxofre livre · Enxofre total · Densidade · pH · Sulfatos · Álcool

DISTRIBUIÇÃO DAS NOTAS

A maioria dos vinhos fica no meio da escala.

Notas 5 e 6 somam 842 dos 1.018 vinhos. Notas 7 e 8, que definimos como alta qualidade, são apenas 137.

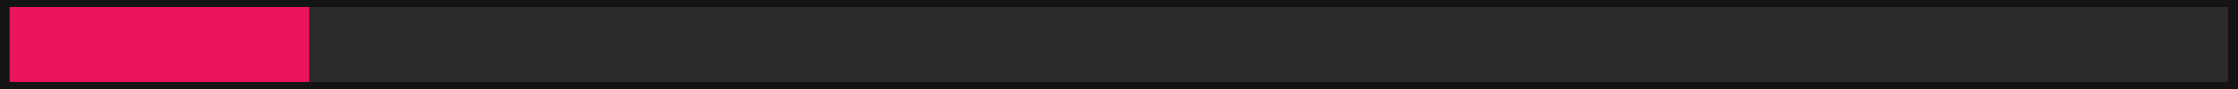


02 · EXPLORAÇÃO DOS DADOS

DESEQUILÍBRIO ENTRE AS CLASSES

13,46%

dos vinhos são de alta qualidade:
137 de 1.018



Alta qualidade · 137

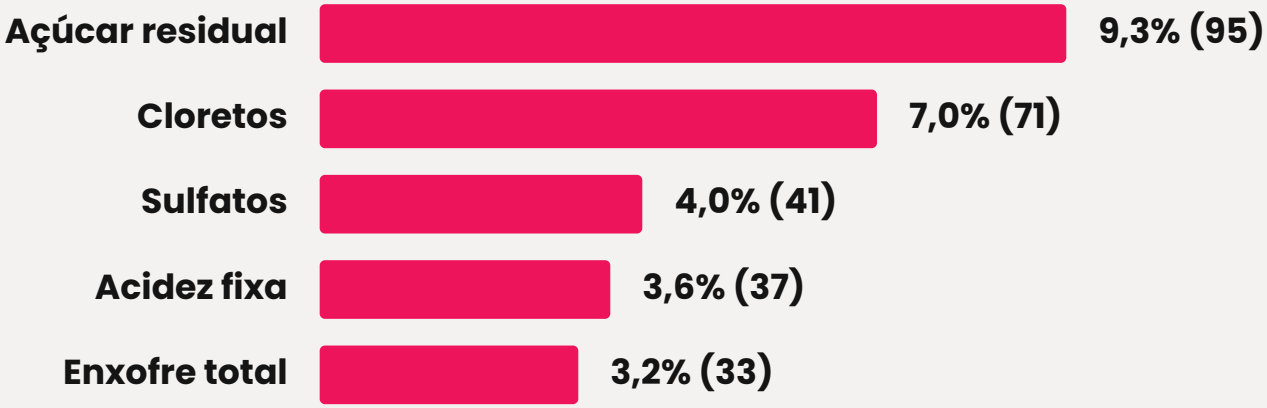
Baixa/média qualidade · 881 (86,54%)

> Por que isso importa: um modelo que respondesse sempre “baixa/média” acertaria cerca de 86,5% das amostras e não encontraria nenhum vinho de alta qualidade. Por isso olhamos precisão, recall e F1, não só a acurácia.

02 · EXPLORAÇÃO DOS DADOS

VALORES EXTREMOS

Medidas com mais registros fora do padrão (% dos 1.018 vinhos)



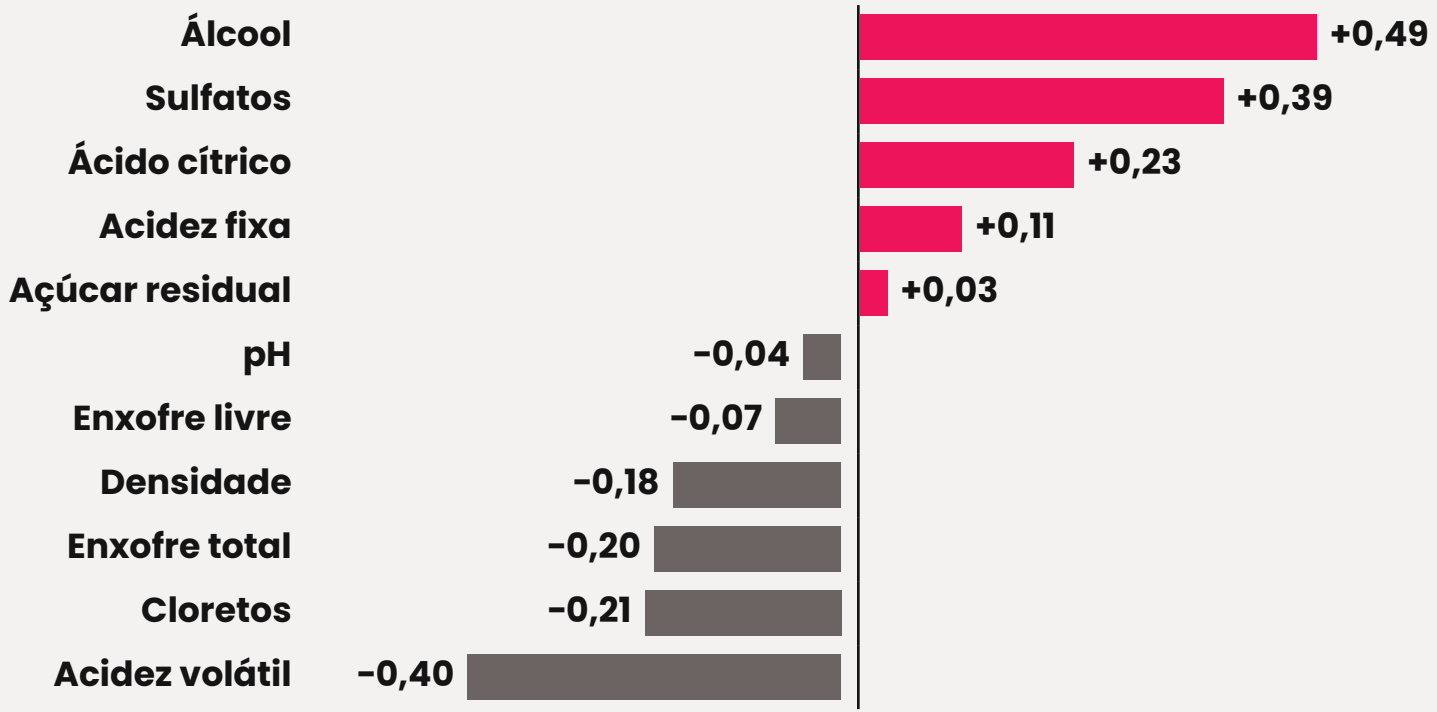
DECISÃO

Mantivemos os valores extremos.

Não encontramos evidência de erro nos registros. Eles foram sinalizados, não removidos.

FIAP · Pós Tech · Tech Challenge Fase 2 · Critério: regra do intervalo interquartil (1,5 × IQR)

QUÍMICA E QUALIDADE



Correlação de Spearman (-1 a +1) com a nota. Enxofre = dióxido de enxofre.

Positiva: álcool e sulfatos mais altos acompanham notas melhores.

Negativa: quanto maior a acidez volátil, piores as notas.

Associação não é causa. Nenhuma medida decide a qualidade sozinha.

PERFIL DO VINHO DE ALTA QUALIDADE

ÁLCOOL

+13%

mais álcool nos vinhos de alta qualidade

Alta qualidade: 11,59%

Demais vinhos: 10,28%

ACIDEZ VOLÁTIL

−29%

menos acidez volátil nos vinhos de alta qualidade

Alta qualidade: 0,39 g/L

Demais vinhos: 0,56 g/L

SULFATOS

+16%

mais sulfatos nos vinhos de alta qualidade

Alta qualidade: 0,75 g/L

Demais vinhos: 0,64 g/L

Médias por grupo. Existem vinhos bons fora desse perfil e vinhos comuns dentro dele: nenhuma medida decide sozinha.

03 · MODELAGEM

COMO CONSTRUÍMOS OS MODELOS

01

Preparar

Duplicados removidos e medidas colocadas na mesma escala.

02

Separar

814 vinhos para treino e 204 para teste, com a mesma proporção de vinhos bons.

03

Treinar

Dois modelos: o KNN compara com vinhos parecidos; o SVM traça uma fronteira entre bons e demais.

04

Ajustar

Configurações testadas em 5 rodadas de validação, com o F1 como critério.

A avaliação final usou 204 vinhos que os modelos nunca tinham visto durante o treino.

03 · MODELAGEM

RESULTADOS DOS MODELOS

Modelo	Acurácia	Precisão	Recall	F1
KNN inicial	87,75%	55,00%	40,74%	46,81%
SVM inicial	89,71%	71,43%	37,04%	48,78%
KNN otimizado	89,22%	63,16%	44,44%	52,17%
SVM otimizado · escolhido	82,84%	41,67%	74,07%	53,33%

Precisão

Dos vinhos que o modelo aponta como bons, quantos realmente são.

Recall

Dos vinhos bons que existem, quantos o modelo consegue encontrar.

F1

Equilíbrio entre precisão e recall; foi o critério de escolha.

03 · MODELAGEM

SVM VERSUS KNN

SVM otimizado

Modelo escolhido

20 de 27

vinhos bons identificados (74%)

28 alarmes falsos

7 vinhos bons não identificados

KNN otimizado

Alternativa

12 de 27

vinhos bons identificados (44%)

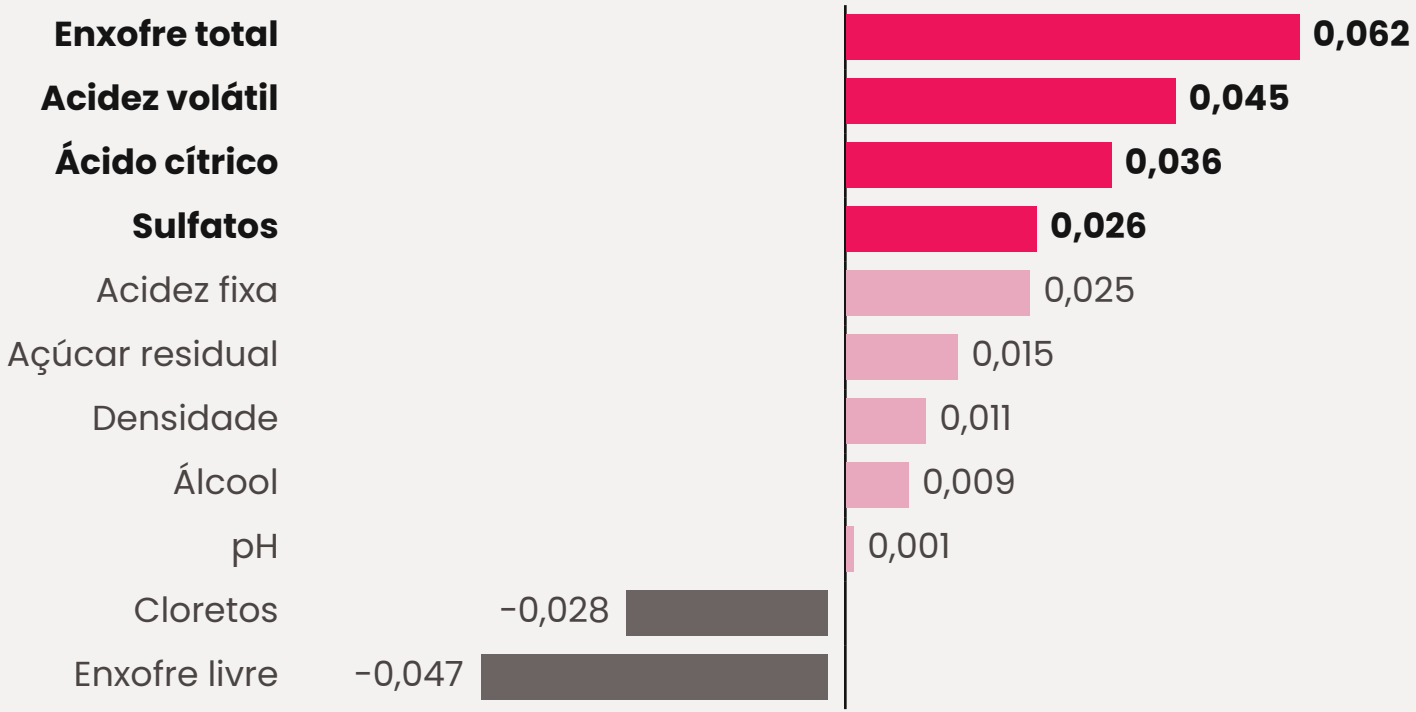
7 alarmes falsos

15 vinhos bons não identificados

Escolha: SVM. Prioriza não perder vinhos bons e aceita mais revisões manuais. Uso ideal: triagem antes da prova do especialista.

03 · MODELAGEM

VARIÁVEIS QUE MAIS PESAM



Queda média do F1 ao embaralhar a variável. Enxofre = dióxido de enxofre.

Os quatro mais relevantes: enxofre total, acidez volátil, ácido cítrico e sulfatos.

As diferenças são pequenas e variam entre as repetições da análise.

O álcool lidera a correlação, mas é o 8º aqui. Relevância para o modelo não é causa.

04 · CONCLUSÕES

IMPLICAÇÕES PARA A PRODUÇÃO

Acompanhar a acidez volátil

Foi 29% menor nos vinhos de alta qualidade e é a 2ª variável mais relevante para o modelo.

Monitorar enxofre e sulfatos

Estão entre as quatro variáveis mais relevantes; os sulfatos foram 16% maiores nos vinhos bons.

Usar como triagem

O modelo aponta cerca de 3 em cada 4 vinhos de alta qualidade para a prova do especialista.

Validar antes de agir

São associações, não causas: mudanças no processo devem ser testadas em ensaios controlados.

04 · CONCLUSÕES

LIMITES E PRÓXIMOS PASSOS

Limitações

- Poucos vinhos de alta qualidade (137), o que dificulta o aprendizado
- Apenas 27 vinhos de alta qualidade no teste
- Duplicados removidos por decisão de preparação, sem confirmar que eram erros
- O modelo ainda erra: 28 alarmes falsos no teste
- Uma única base: os resultados precisam de novos dados

Próximos passos

- Avaliar os modelos em novas amostras
- Reduzir as classificações incorretas
- Verificar se o desempenho se mantém em diferentes situações

04 · CONCLUSÃO

APOIO À DECISÃO, NÃO SUBSTITUTO DO ESPECIALISTA

74%
dos vinhos de alta qualidade encontrados no teste (20 de 27)

28
alarmes falsos entre os 204 vinhos de teste

13,46%
da base é de alta qualidade: o maior desafio dos modelos

Obrigado!

Aneli Eiko Abe
Carolina Estevam Rodgerio
João Vitor Morais Santos
Luis Felipe Brum Marinato
Pedro Andrade da Silva