PÓS TECH - DATA ANALYTICS



FASE 2 - TECH CHALLENGE

Grupo 8:

Aneli Eiko Abe, RM 376937

Carolina Estevam Rodgerio, RM 376656

João Vitor Morais Santos, RM 376791

Luis Felipe Brum Marinato, RM 375960

Pedro Andrade da Silva, RM 376960

03 de Novembro de 2026

Criação de modelos de machine learning para classificação de vinhos

Introdução

A indústria vinícola possui grande relevância econômica e cultural em diversos países. Tradicionalmente, a avaliação da qualidade de um vinho é realizada por especialistas, por meio de análises sensoriais, que consideram aspectos como aroma, sabor, acidez e equilíbrio. No entanto, esse processo pode ser subjetivo e demandar tempo, além de depender da experiência dos avaliadores.

Com o avanço das técnicas de ciência de dados e aprendizado de máquina, tornou-se possível utilizar dados físico-químicos obtidos durante a produção do vinho para auxiliar na previsão da qualidade final do produto. Dessa forma, modelos preditivos podem apoiar enólogos e produtores na tomada de decisão, permitindo ajustes no processo produtivo e contribuindo para a padronização da qualidade.

O dataset utilizado possui informações de propriedades físico-químicas de diversas amostras de vinhos. Esses dados foram analisados, tratados e utilizados para o desenvolvimento de modelos preditivos capazes de prever a qualidade de um vinho a partir de suas características.

Objetivo

O objetivo é treinar e avaliar modelos de aprendizado de máquina capazes de prever a classificação de vinhos a partir das variáveis disponíveis.

Dados e Análises Preliminares

O dataset utilizado para análise e desenvolvimento dos modelos preditivos foi o Wine Quality Dataset, disponível na plataforma Kaggle. O dataset possui colunas com diferentes propriedades físico-químicas presentes nos vinhos e suas notas.

Antes de desenvolver os modelos preditivos, foi feita uma análise exploratória e tratamento dos dados. Foi observado que:

- O dataset original apresenta 1.143 registros e 13 colunas;
- Não foram identificados valores Nulos;
- Foram identificadas 125 linhas repetidas, que foram removidas e mantidas apenas as primeiras ocorrências, já que a presença de repetições pode

enviesar os modelos. O dataset ficou com 1018 registros para serem analisados, tratados e utilizados nos modelos preditivos.

Análise Exploratória dos Dados

1. Análise da distribuição dos vinhos por qualidade

Foi feita uma análise na coluna “quality” para verificar a distribuição dos vinhos nas notas. Além disso, foi criada uma nova coluna para classificar os vinhos em:

- Vinhos de baixa/média qualidade (0): notas inferiores a 7.
- Vinhos de alta qualidade (1): notas iguais ou superiores a 7.

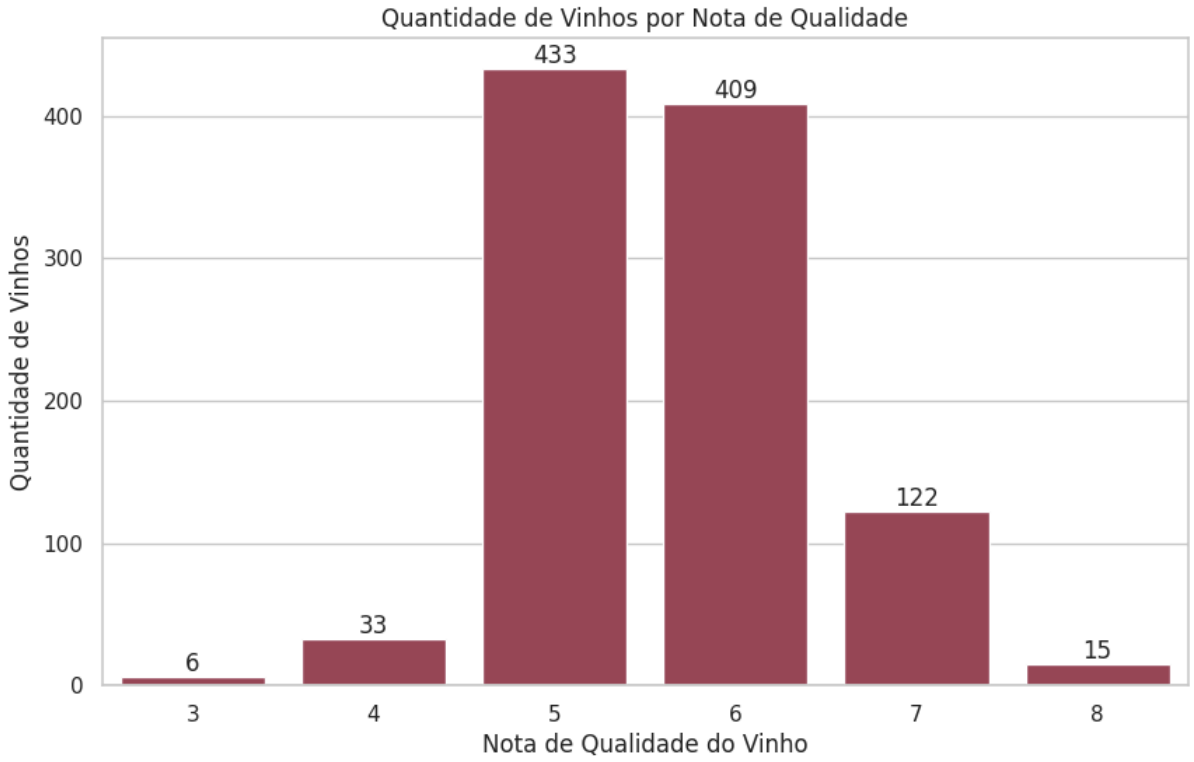


Figura 1. Quantidade de vinhos por nota.

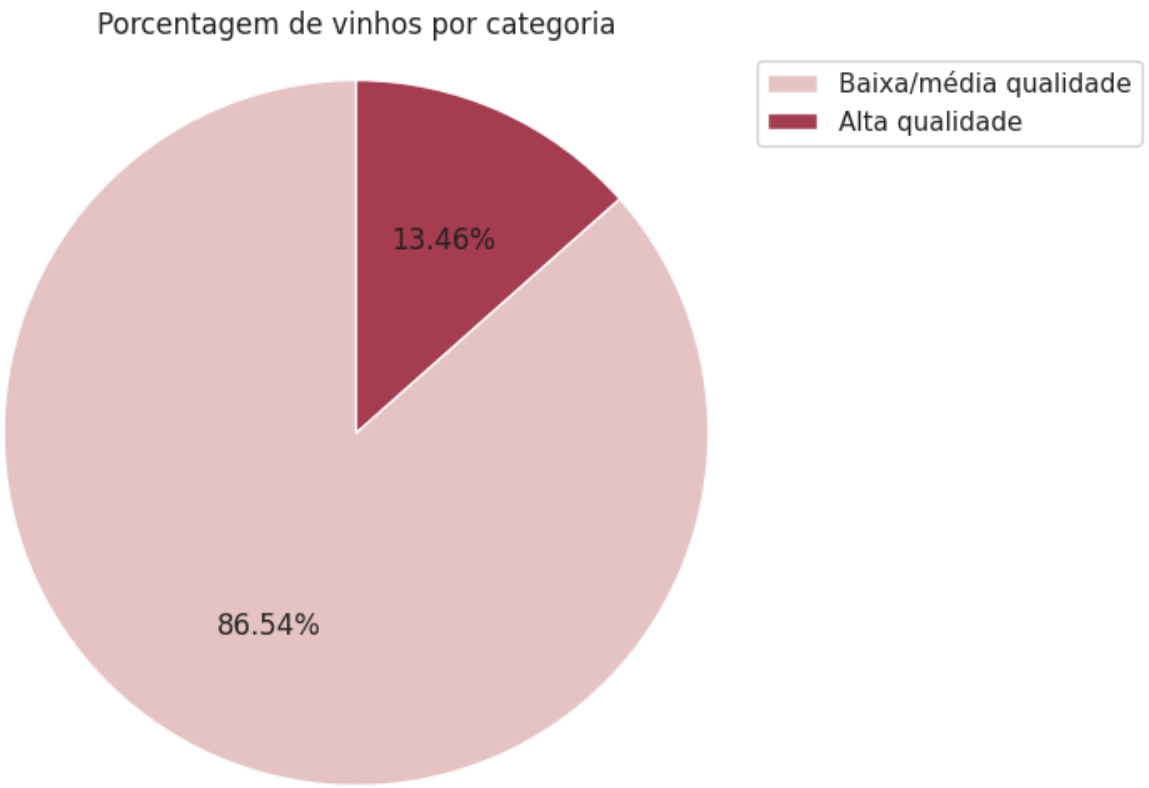


Figura 2. Gráficos da Porcentagem de vinhos por categoria.

As notas de qualidade dos vinhos analisados variam de 3 a 8 (figura 1). A distribuição demonstra desequilíbrio entre as categorias, com 881 registros de vinhos de baixa/média qualidade (figura 1), representando mais de 86% dos vinhos analisados (figura 2). Os vinhos de alta qualidade representam apenas 13,46% do total de vinhos (figura 2), com apenas 137 registros (figura 1).

2. Análise descritiva e de presença de possíveis outliers

Foi feita a análise descritiva das colunas para verificar informações das médias, medianas, valores mínimos e máximos, desvio padrão e valores dos quartis das colunas do dataset.

	count	mean	std	min	25%	50%	75%	max
fixed acidity	1018.0	8.289	1.741	4.600	7.100	7.900	9.100	15.900
volatile acidity	1018.0	0.534	0.183	0.120	0.390	0.520	0.645	1.580
citric acid	1018.0	0.269	0.196	0.000	0.090	0.250	0.420	1.000
residual sugar	1018.0	2.524	1.315	0.900	1.900	2.200	2.600	15.500
chlorides	1018.0	0.087	0.049	0.012	0.070	0.079	0.090	0.611
free sulfur dioxide	1018.0	15.649	10.177	1.000	7.000	13.000	21.000	68.000
total sulfur dioxide	1018.0	46.326	33.124	6.000	21.000	38.000	62.000	289.000
density	1018.0	0.997	0.002	0.990	0.996	0.997	0.998	1.004
pH	1018.0	3.312	0.158	2.740	3.210	3.310	3.400	4.010
sulphates	1018.0	0.657	0.168	0.330	0.550	0.620	0.720	2.000
alcohol	1018.0	10.452	1.095	8.400	9.500	10.200	11.200	14.900
quality	1018.0	5.641	0.812	3.000	5.000	6.000	6.000	8.000
alta_qualidade	1018.0	0.135	0.341	0.000	0.000	0.000	0.000	1.000

Tabela 1. Descrição das categorias.

A análise descritiva das colunas mostrou que as variáveis 'fixed acidity', 'residual sugar', 'chlorides', 'free sulfur dioxide' e 'total sulfur dioxide' apresentaram valores máximos discrepantes em relação às suas médias.

Foram gerados gráficos de violino e boxplot destas variáveis para avaliar a distribuição dos dados e identificar possíveis outliers. Além disso, foi feita também a análise de outliers pelo Método do Intervalo Interquartil (IQR).

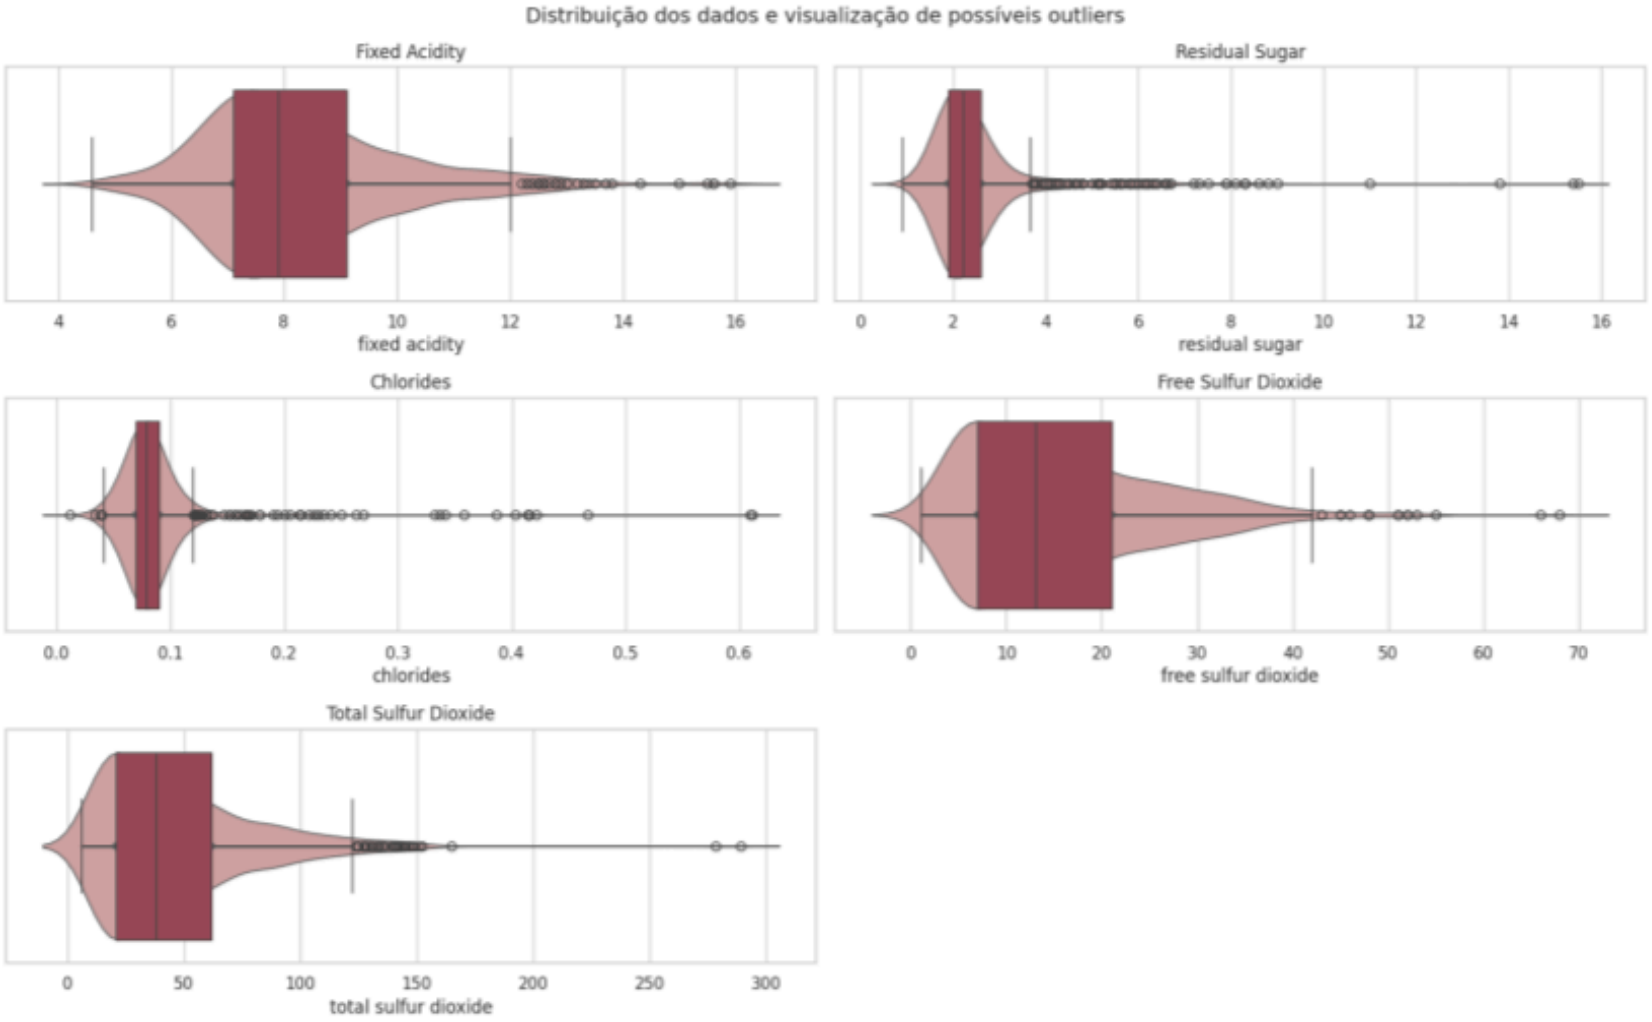


Figura 3 Gráficos de distribuição dos dados e visualização de possíveis outliers.

	feature	lower_bound	upper_bound	outliers	percentage
3	residual sugar	0.85	3.65	95	9.33
4	chlorides	0.04	0.12	71	6.97
9	sulphates	0.30	0.97	41	4.03
0	fixed acidity	4.10	12.10	37	3.63
6	total sulfur dioxide	-40.50	123.50	33	3.24
7	density	0.99	1.00	30	2.95
8	pH	2.92	3.68	24	2.36
5	free sulfur dioxide	-14.00	42.00	16	1.57
1	volatile acidity	0.01	1.03	10	0.98
10	alcohol	6.95	13.75	6	0.59
2	citric acid	-0.40	0.91	1	0.10

Tabela 2. Análise de possíveis outliers pelo método IQR.

Os gráficos evidenciaram a presença de valores isolados significativamente acima do terceiro quartil (Q3), justificando as discrepâncias observadas (figura 3). A partir do cálculo do intervalo interquartil (IQR), a variável 'residual sugar' apresentou o maior número de outliers (95), correspondendo a mais de 9% dos registros, enquanto 'citric acid' apresentou apenas um (tabela 2).

Optou-se por não remover os valores extremos do dataset, uma vez que não foram identificadas evidências de erros nos registros que justificassem sua exclusão.

3. Análise de correlação entre as medidas e a qualidade dos vinhos

Para analisar a relação entre as características físico-químicas e a qualidade dos vinhos, foi utilizado o coeficiente de correlação de Spearman, método que permite identificar associações monotônicas entre variáveis, em que à medida que uma variável aumenta, a outra variável tende a sempre aumentar ou a sempre diminuir, mas não necessariamente de forma linear. O método foi escolhido por ser menos sensível a valores extremos e por não exigir que os dados apresentem distribuição normal.

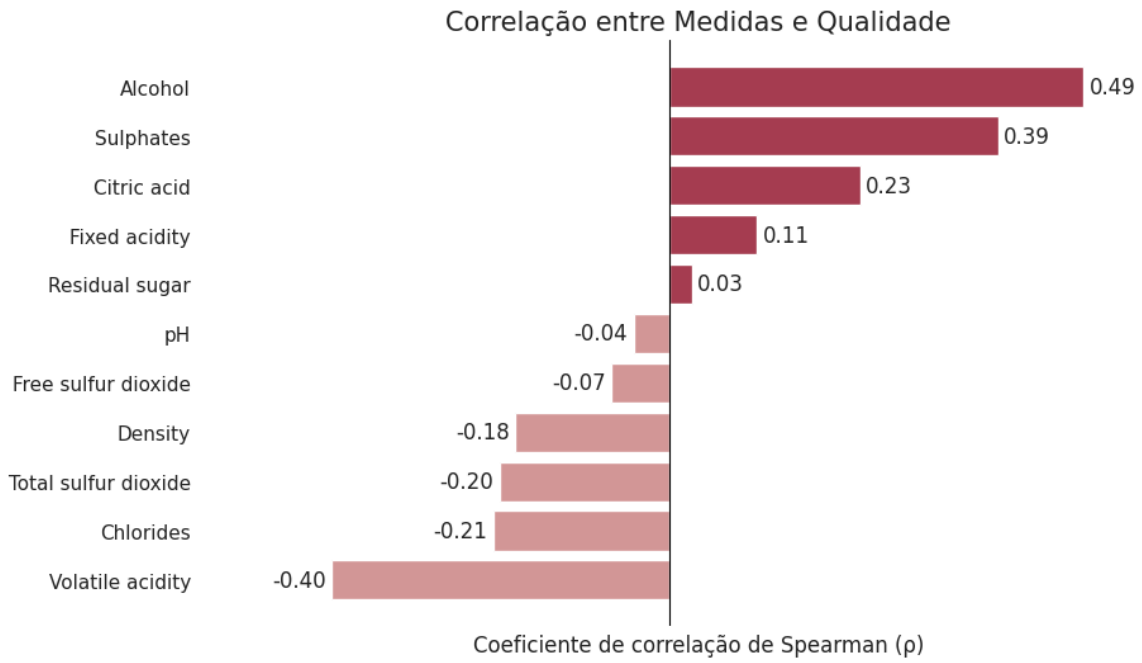


Figura 4 Gráfico de correlação entre a qualidade e as características físico-químicas.

Pode-se observar no gráfico gerado que as variáveis Álcool e sulfatos (‘Alcohol’ e ‘Sulphates’) apresentaram associação positiva moderada com a qualidade (0,49 e 0,39, respectivamente), tendo os vinhos de maiores notas apresentado tendência a ter maior teor alcoólico e de sulfatos (figura 4). Já a variável acidez volátil ('volatile acidity') apresentou associação negativa moderada com a nota de qualidade (0,4) (figura 4).

A partir desta observação, foram gerados gráficos boxplot destas variáveis para analisar a distribuição dos vinhos nas diferentes notas de qualidade.

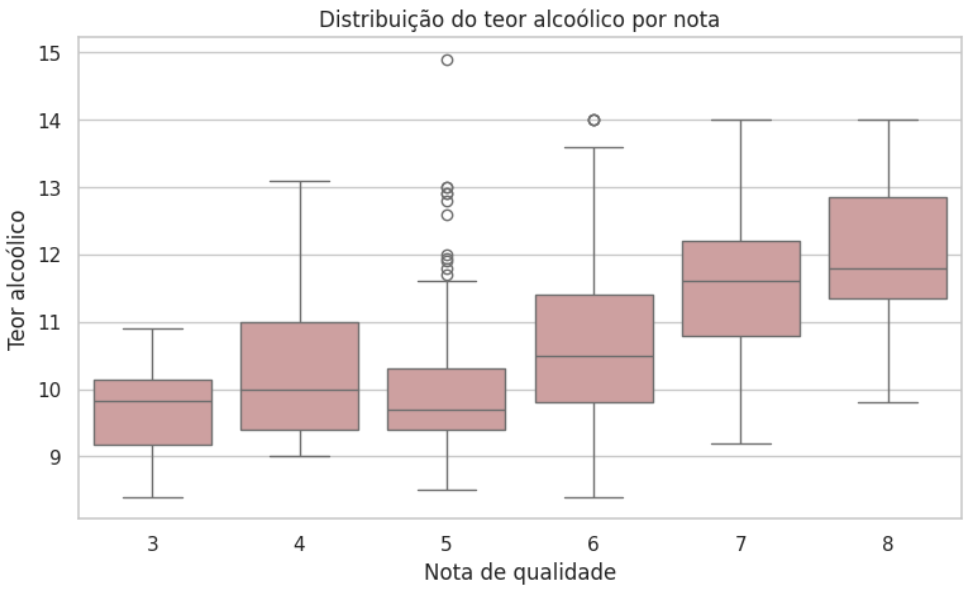


Figura 5 Distribuição do teor alcoólico por nota.

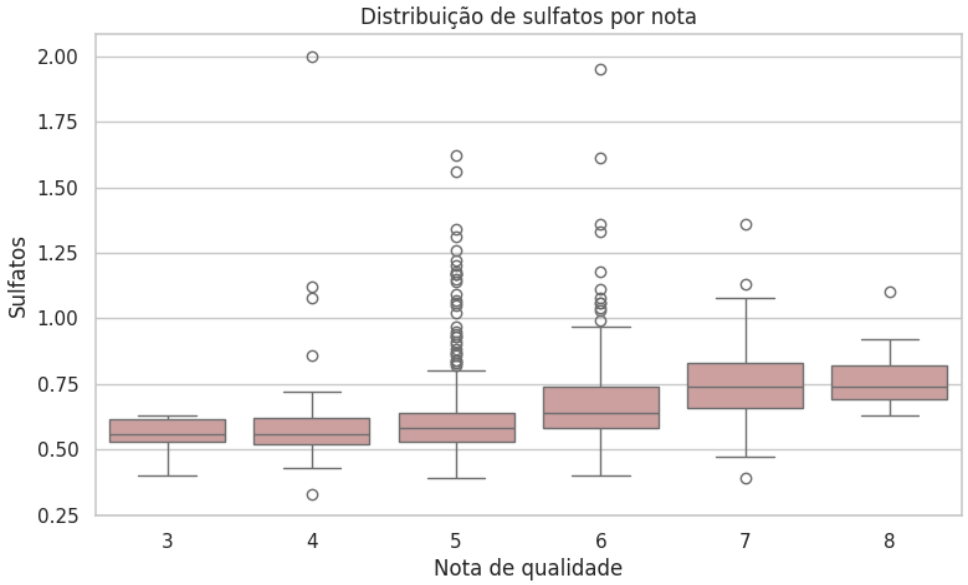


Figura 6 Distribuição de sulfatos por nota.

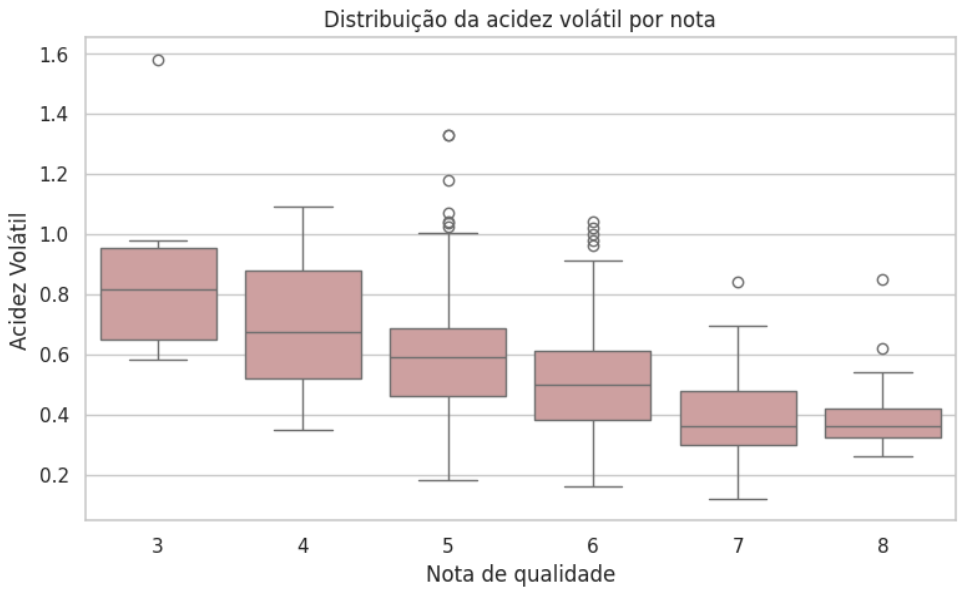


Figura 7 Distribuição da acidez volátil por nota

Quando analisados os gráficos de boxplot, pode-se observar que existem vinhos de baixa/média qualidade que também apresentam valores mais altos de álcool e sulfatos (figura 5 e 6). Os gráficos de boxplot da acidez volátil mostram que os vinhos de maior qualidade tendem a ter menor acidez. No entanto, alguns vinhos classificados como de baixa/média qualidade também apresentaram menores quantidades de acidez volátil (figura 7).

As sobreposições observadas nos gráficos de boxplot das variáveis analisadas indicam que estas não podem ser utilizadas isoladamente para determinar a qualidade do vinho.

Criação de modelos preditivos

Para a criação dos modelos preditivos que ajudem a classificar os vinhos utilizando as características físico-químicas, foram utilizados os algoritmos K-Nearest Neighbors (KNN) e Support Vector Machine (SVM).

Os dados utilizados na modelagem foram separados para treino e teste, e foi feita a padronização dos dados utilizados para treinamento.

1. **K-Nearest Neighbors**

   Foi utilizado k= 5

2. **Support Vector Machine**

   Foi utilizado o kernel RBF, que permite representar relações não lineares.

Cálculo das métricas dos modelos

	Modelo	Acurácia	Precisão	Recall	F1-score
0	KNN inicial	0.8775	0.5500	0.4074	0.4681
1	SVM inicial	0.8971	0.7143	0.3704	0.4878

```
Matriz de confusão – KNN inicial:
[[168   9]
 [ 16  11]]

Matriz de confusão – SVM inicial:
[[173   4]
 [ 17  10]]
```

Tabela 3. Métricas aplicadas nos modelos utilizados.

Para avaliar os modelos, foram utilizadas as métricas de acurácia, precisão, recall e F1-score, além da matriz de confusão, que apresenta a quantidade de acertos e erros de cada modelo. A avaliação foi realizada com 204 vinhos separados para teste, dos quais 27 são de alta qualidade.

Pode-se observar que os dois modelos apresentaram acurácia elevada, de 87,75% no KNN e 89,71% no SVM (tabela 3). No entanto, a acurácia não é a métrica mais adequada para este problema. Como a base é desbalanceada, um modelo que classifica todos os vinhos como de

baixa/média qualidade acertaria 86,76% dos casos sem identificar nenhum vinho de alta qualidade.

Ao analisar o recall, observa-se que o KNN identificou 11 dos 27 vinhos de alta qualidade (40,74%) e o SVM identificou 10 (37,04%) (tabela 3). Ou seja, as versões iniciais dos modelos deixaram de identificar mais da metade dos vinhos de alta qualidade.

Melhorando o desempenho dos modelos

Após a avaliação das versões iniciais, foram testadas diferentes configurações dos modelos em busca de melhores resultados:

- **KNN:** foi testada a quantidade de vizinhos considerados na classificação (3, 5, 7, 9 e 11).
- **SVM:** foram testados diferentes níveis de penalização de erros (parâmetro C: 0,1, 1 e 10), com e sem balanceamento de pesos entre as classes. O balanceamento dá mais importância aos vinhos de alta qualidade durante o treinamento, por serem minoria na base.

Devido ao desbalanceamento, o F1-score foi utilizado como principal critério de comparação. Ele considera ao mesmo tempo:

- a **precisão**: entre os vinhos apontados como de alta qualidade, quantos realmente são;
- o **recall**: entre os vinhos de alta qualidade, quantos o modelo identificou.

Para comparar as configurações, foi utilizada a validação cruzada com cinco divisões. Nela, os dados de treinamento são divididos em cinco partes: o modelo aprende com quatro partes e é avaliado na parte restante. O processo se repete até que todas as partes tenham sido utilizadas na avaliação e, ao final, é calculada a média dos resultados. Os dados de teste não foram utilizados nesta etapa, sendo reservados para a avaliação final.

```
Melhores parâmetros do KNN:
{'knn__n_neighbors': 7}

Melhor F1-score médio:
0.4417
```

	param_knn__n_neighbors	mean_test_score	std_test_score
0	3	0.395824	0.067105
1	5	0.399248	0.096853
2	7	0.441683	0.119688
3	9	0.388909	0.133053
4	11	0.363929	0.114978

Tabela 4. Resultados da validação cruzada do KNN.

```
Melhores parâmetros do SVM:
{'svm__C': 1, 'svm__class_weight': 'balanced'}

Melhor F1-score médio:
0.5063
```

	param_svm__C	param_svm__class_weight	mean_test_score	std_test_score
3	1.0	balanced	0.506303	0.046837
5	10.0	balanced	0.500111	0.070914
1	0.1	balanced	0.490690	0.034883
4	10.0	None	0.447026	0.093769
2	1.0	None	0.364067	0.119266
0	0.1	None	0.000000	0.000000

Tabela 5. Resultados da validação cruzada do SVM.

Pode-se observar que o KNN apresentou o melhor resultado com 7 vizinhos, com F1-score médio de 44,17% (tabela 4). Já o SVM apresentou o melhor resultado com C igual a 1 e balanceamento de pesos, com F1-score médio de 50,63% (tabela 5). Nota-se também que, no SVM, todas as configurações com balanceamento de pesos apresentaram resultados superiores às configurações sem balanceamento (tabela 5).

Por apresentar o maior F1-score médio na validação cruzada, o SVM foi selecionado como modelo principal.

Avaliação final dos modelos

Os modelos com as melhores configurações foram avaliados nos 204 vinhos de teste e comparados com suas versões iniciais.

	Modelo	Acurácia	Precisão	Recall	F1-score
0	KNN inicial	0.8775	0.5500	0.4074	0.4681
1	SVM inicial	0.8971	0.7143	0.3704	0.4878
2	KNN otimizado	0.8922	0.6316	0.4444	0.5217
3	SVM otimizado	0.8284	0.4167	0.7407	0.5333

```
Matriz de confusão – KNN otimizado:
[[170   7]
 [ 15  12]]

Matriz de confusão – SVM otimizado:
[[149  28]
 [  7  20]]

Modelo principal selecionado pela validação cruzada: SVM
```

Tabela 6. Comparação das métricas dos modelos iniciais e otimizados.

Pode-se observar que os dois modelos otimizados apresentaram F1-score superior às suas versões iniciais (tabela 6):

- **KNN otimizado:** alcançou maior acurácia (89,22%) e precisão (63,16%). Identificou 12 dos 27 vinhos de alta qualidade e classificou incorretamente 7 vinhos como de alta qualidade.
- **SVM otimizado:** apresentou o maior recall (74,07%) e identificou 20 dos 27 vinhos de alta qualidade. Porém, classificou incorretamente 28 vinhos de baixa/média qualidade como de alta qualidade, o que reduziu sua precisão para 41,67%.

O SVM otimizado obteve F1-score de 53,33%, ligeiramente superior aos 52,17% do KNN otimizado. Dessa forma, nenhum modelo apresentou os melhores resultados em todas as métricas: o KNN erra menos ao apontar um vinho como de alta qualidade, enquanto o SVM identifica uma parcela maior desses vinhos.

O SVM foi considerado a opção mais adequada para uma aplicação de triagem, na qual os vinhos apontados pelo modelo ainda passariam por uma avaliação especializada. Nesse cenário, é preferível encaminhar alguns vinhos a mais para avaliação do que deixar de identificar vinhos de alta qualidade.

Importância das variáveis

Para identificar quais características mais influenciaram as previsões do SVM, foi utilizada a importância por permutação. Essa técnica embaralha os valores de uma característica por vez e mede o quanto o desempenho do modelo diminui: quanto maior a queda, mais o modelo depende daquela característica. A análise foi realizada em uma parte separada dos dados de treinamento, sem utilizar os dados de teste.

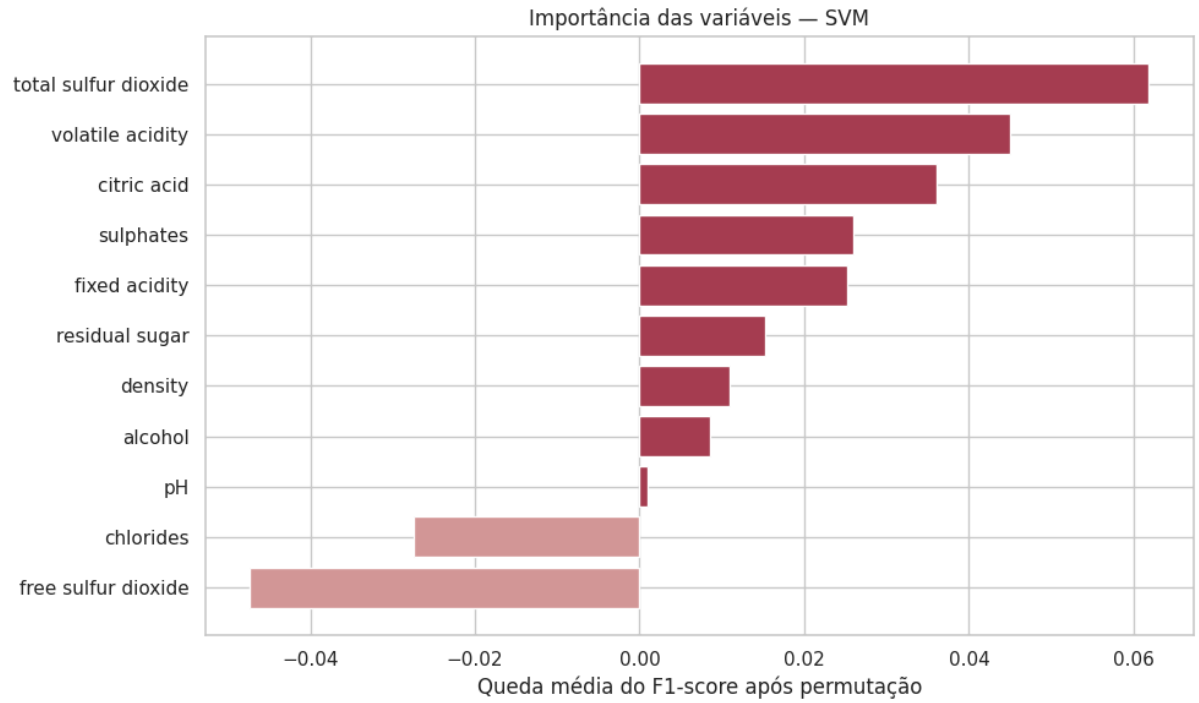


Figura 9. Importância das variáveis para o modelo SVM.

Pode-se observar que as características com maior importância foram o dióxido de enxofre total (0,0619), a acidez volátil (0,0449), o ácido cítrico (0,0361) e os sulfatos (0,0260) (figura 9). Os cloretos e o dióxido de enxofre livre apresentaram importância negativa, indicando que embaralhar seus valores não prejudicou o desempenho do modelo nesta avaliação.

As diferenças entre as importâncias foram pequenas e variaram entre as repetições da análise. Além disso, o teor alcoólico, que apresentou a maior correlação com a qualidade na análise exploratória, teve baixa importância para o modelo (0,0085). Por isso, esses resultados devem ser interpretados com cautela e não permitem afirmar que uma característica cause mudanças na qualidade do vinho.

Implicações para o processo de produção

Os resultados indicam pontos de atenção no processo produtivo:

- **Acidez volátil:** foi a característica com maior associação negativa com a qualidade e uma das mais importantes para o modelo. Controlar a fermentação e a higiene do processo, evitando a contaminação por bactérias que produzem ácido acético, pode ajudar a manter essa medida baixa.
- **Teor alcoólico:** os vinhos de alta qualidade apresentaram, em média, cerca de 13% mais álcool. O ponto de colheita da uva e uma fermentação bem conduzida influenciam essa medida.
- **Sulfatos e dióxido de enxofre:** os sulfatos apareceram associados a vinhos melhores, enquanto o excesso de SO_2 total apareceu associado a notas menores, o que indica a importância de dosar corretamente os conservantes.
- **Uso das medidas de laboratório:** como essas características já são medidas durante a produção, o modelo pode ser utilizado como uma triagem antes da avaliação sensorial, ajudando a priorizar quais lotes devem ser avaliados primeiro pelos especialistas.

Como as análises mostram associações e não relações de causa e efeito, qualquer mudança no processo deve ser testada em pequena escala antes de ser adotada.

Conclusão

O objetivo deste trabalho foi avaliar se as características físico-químicas dos vinhos poderiam ser utilizadas para identificar aqueles de alta qualidade (nota igual ou superior a 7). Após a remoção de 125 registros duplicados, foram analisados 1.018 vinhos, dos quais apenas 13,46% eram de alta qualidade.

A análise exploratória mostrou que vinhos de alta qualidade tendem a apresentar maior teor alcoólico, menor acidez volátil e maior concentração de sulfatos. No entanto, as sobreposições entre as categorias indicam que nenhuma característica deve ser utilizada isoladamente para determinar a qualidade.

Foram desenvolvidos dois modelos de classificação, KNN e SVM. O SVM otimizado foi selecionado como modelo principal, identificando 20 dos 27 vinhos de alta qualidade do conjunto de teste (recall de 74,07%), mas com precisão de 41,67%.

O estudo apresenta algumas limitações:

- A quantidade de vinhos de alta qualidade é pequena, o que dificulta o aprendizado dessa categoria.
- O conjunto de teste contém apenas 27 vinhos de alta qualidade.
- Os resultados foram obtidos com uma base específica e precisam ser confirmados com novos dados antes de qualquer utilização prática.

Conclui-se que a solução desenvolvida apresenta potencial como ferramenta de apoio à análise da qualidade dos vinhos, especialmente como triagem. Porém, ela não está pronta para substituir avaliações especializadas ou tomar decisões de produção de forma automática.